MACHINE LEARNING • HOMEWORK 02

多元線性回歸分析與特徵選擇

以 Kaggle 洪水機率預測資料集為例

CRISP-DM 六階段研究報告

學號

7115056050

作業名稱

HW2 • Multiple Linear Regression

實作環境

Google Colab • Python

報告日期

2026 年 10 月 17 日

資料依據：學生實際執行的 Jupyter Notebook、NotebookLM 研究紀錄與所提供的截圖。

摘要與研究架構

本研究使用 Kaggle「Regression with a Flood Prediction Dataset」進行多元線性回歸預測，依循 CRISP-DM 流程完成商業理解、資料理解、資料準備、模型建立、評估與應用示範。資料集包含 1,117,957 筆觀測、20 個數值輸入特徵與一個目標欄位 FloodProbability。研究使用 SelectKBest 與 f_regression 挑選 15 個特徵，比較保留 20 個特徵與精簡 15 個特徵的線性回歸模型。

1,117,957	20 → 15	0.844877
訓練資料筆數	特徵數量比較	最佳模型 R^2

根據測試集評估，完整特徵模型 A 的 R^2 為 0.844877，明顯高於篩選後模型 B 的 0.595773，且其 MAE、MSE、RMSE 均較低；因此本研究選擇模型 A 作為最終模型。以 OLS 估計的 95% 預測區間對抽樣 100 筆測試資料達到 95% 的觀察涵蓋率。此結果為競賽資料與特定抽樣下的實驗發現，不代表真實洪水風險已獲驗證。

> **核心發現：**採用較少特徵不必然提升預測效果；單變量統計特徵篩選與多變量模型最適特徵組合並不完全相同。

研究流程

CRISP-DM 階段	本研究工作
1. Business Understanding	定義洪水機率預測目標、研究問題與限制
2. Data Understanding	檢查資料型態、缺失值及特徵相關係數
3. Data Preparation	排除 id、指定 X/y、80%/20% 資料分割
4. Modeling	SelectKBest 特徵篩選、訓練兩個線性回歸模型
5. Evaluation	MAE、MSE、RMSE、R^2、散佈圖、預測區間
6. Deployment	對單筆模擬資料進行推論，討論未來應用

1. Business Understanding（商業理解）

1.1 背景與動機

洪水可能造成生命、財產與基礎設施損失。透過資料分析研究與洪水風險評分有關的因素，可練習多變量預測方法。本研究以 Kaggle 競賽資料為分析對象，著重機器學習方法的操作與比較，非實際地區的洪水預警評估。

1.2 研究目標

- 使用 20 個數值特徵預測資料集中的 FloodProbability。
- 比較使用全部 20 個特徵和 SelectKBest 篩選 15 個特徵的模型表現。
- 分析哪些特徵與目標值具有較強的單變量線性關聯。
- 透過誤差指標與預測圖，討論線性回歸的適用性與限制。

1.3 衡量標準

採用 MAE、MSE、RMSE 與 R^2 衡量未見測試資料的預測表現；前 3 項越低越好，R^2 越高通常越好。另以預測散佈圖與模型式 95% 預測區間呈現估計誤差與不確定性。

1.4 研究範圍及限制

> FloodProbability 是該競賽資料中的連續型目標值，不能在未經額外資料驗證與機率校準前，直接等同於某地區的真實洪水發生機率。

2. Data Understanding（資料理解）

資料來源：Kaggle · Regression with a Flood Prediction Dataset

資料屬性	實際檢查結果
樣本筆數	1,117,957 筆
總欄位數	22 欄：id、20 個特徵、FloodProbability
資料型態	21 個 int64 欄位、1 個 float64 欄位
缺失值	22 個欄位均為 0 筆
本次目標	FloodProbability（連續型數值）

全部輸入欄位均為數值型態，因此本次未額外進行類別編碼；也無須補缺失值。實驗剔除 id，避免模型將流水編號誤認為有解釋力的因素。

2. Data Understanding（續）：特徵關聯分析

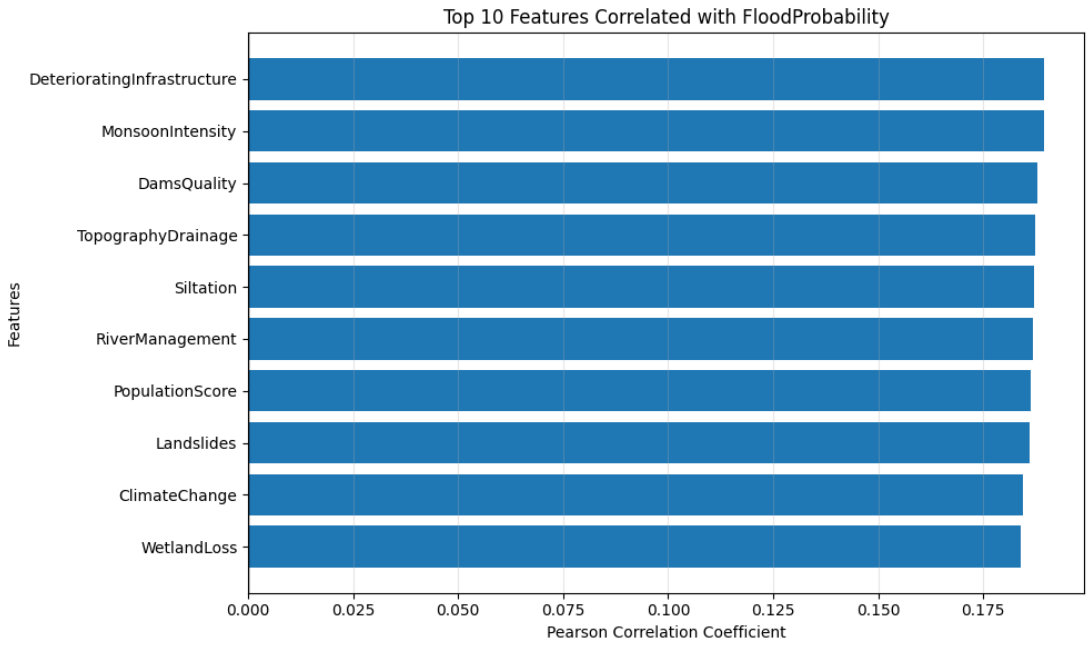


圖 1　與 FloodProbability 相關性最高的 10 個特徵（Notebook 原始輸出）

使用 Pearson 相關係數衡量單一特徵與目標值的線性關聯。前三名為 DeterioratingInfrastructure（0.189532）、MonsoonIntensity（0.189400）與 DamsQuality（0.188017）；前十名約介於 0.184～0.190，屬偏弱的正相關。

> 單一特徵的 Pearson 相關係數偏低，不代表多個特徵結合後無法預測；同樣地，相關性不代表因果關係，也不等於特徵對預測結果的獨立貢獻。

3. Data Preparation（資料準備）

3.1 資料處理

使用 **X = df.drop(columns=['id', 'FloodProbability'])** 取出 20 個輸入特徵，以 **y = df['FloodProbability']** 定義預測目標。由於缺失值為 0，本次沒有執行填補。模型前處理與統計篩選僅用訓練資料進行。

3.2 訓練集／測試集

資料集	比例	筆數	特徵數
訓練集	80%	894,365	20
測試集	20%	223,592	20

分割設定：test_size=0.2、random_state=42；測試集不參與特徵篩選。

4. Modeling（模型建立）

4.1 特徵選擇：SelectKBest + f_regression

使用 SelectKBest，以 f_regression 對每項特徵與目標值之間的單變量線性關聯進行 F 分數評估，依排名保留前 15 個特徵。此方法的優點是易於實作且運算成本低；限制是每次獨立評分，不直接考慮不同特徵的交互作用或組合效果。

20	15	25%
原始特徵	保留特徵	特徵數減少比例

4.2 篩選結果摘要

名次	特徵	F 分數
1	DeterioratingInfrastructure	33,324.882
2	MonsoonIntensity	33,276.472
3	DamsQuality	32,774.785
4	TopographyDrainage	32,562.796
5	Siltation	32,493.002

表中 F 分數為輸出值四捨五入至小數第 3 位；F 分數大小不等於因果效果，也不應直接比較不同研究或資料量。

4.3 模型設定

模型	演算法	特徵	比較目的
模型 A	LinearRegression（OLS）	全部 20 個	完整特徵基準模型
模型 B	LinearRegression（OLS）	SelectKBest 保留 15 個	檢查精簡特徵的影響

兩組使用相同 train/test 分割；模型由訓練集估計係數，再對相同測試集進行預測。

5. Evaluation（模型評估）

5.1 四項評估指標

指標	模型 A ・ 20 特徵	模型 B ・ 15 特徵	判讀方向
MAE	**0.015792**	0.026109	越低越好
MSE	**0.000403**	0.001051	越低越好
RMSE	**0.020080**	0.032414	越低越好
R^2	**0.844877**	0.595773	越高越好

模型 A 的三項誤差指標均較小，R^2 達 0.844877，能解釋約 84.49% 的測試目標值變異；模型 B 的 R^2 為 0.595773。當特徵從 20 個降至 15 個後，R^2 下降約 0.2491，這組篩選方案未改善預測表現。

5.2 實際值與預測值

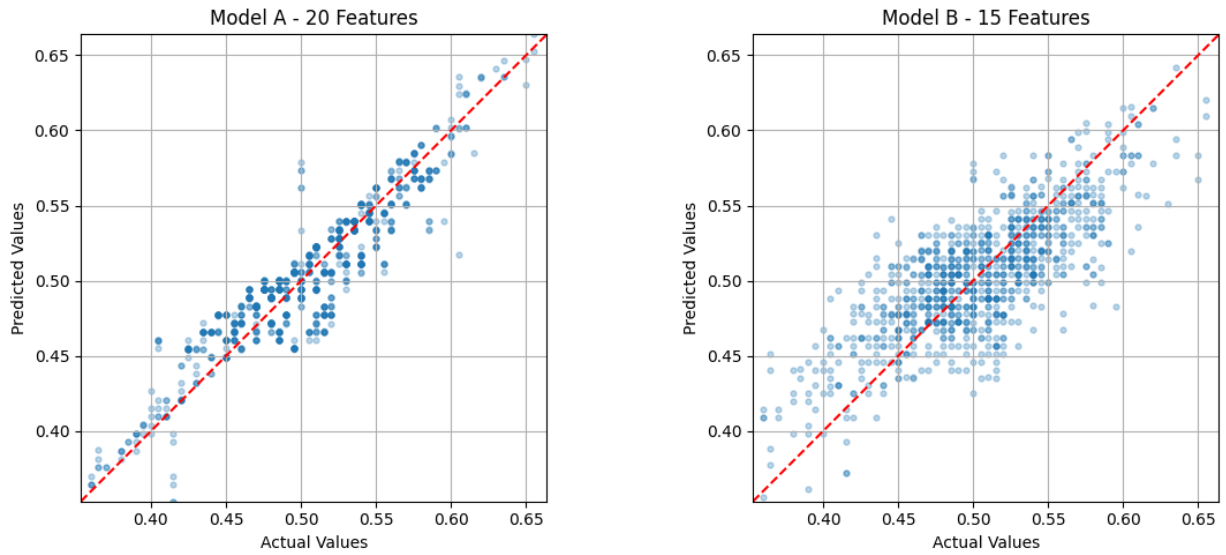


圖 2　模型 A 與模型 B 的實際值／預測值散佈圖（測試集隨機抽樣 1,000 筆）

紅色虛線是完全預測的 y=x 參考線。模型 A 的預測點相對集中於參考線附近；模型 B 更分散，與誤差指標結果一致。

5. Evaluation（續）：預測區間

5.3 95% Prediction Interval

以模型 A 的 20 個特徵建立 statsmodels OLS 模型，計算個別新觀測值的 95% 預測區間（obs_ci_lower／obs_ci_upper）。從測試集隨機抽取 100 筆，依預測值排序繪圖。

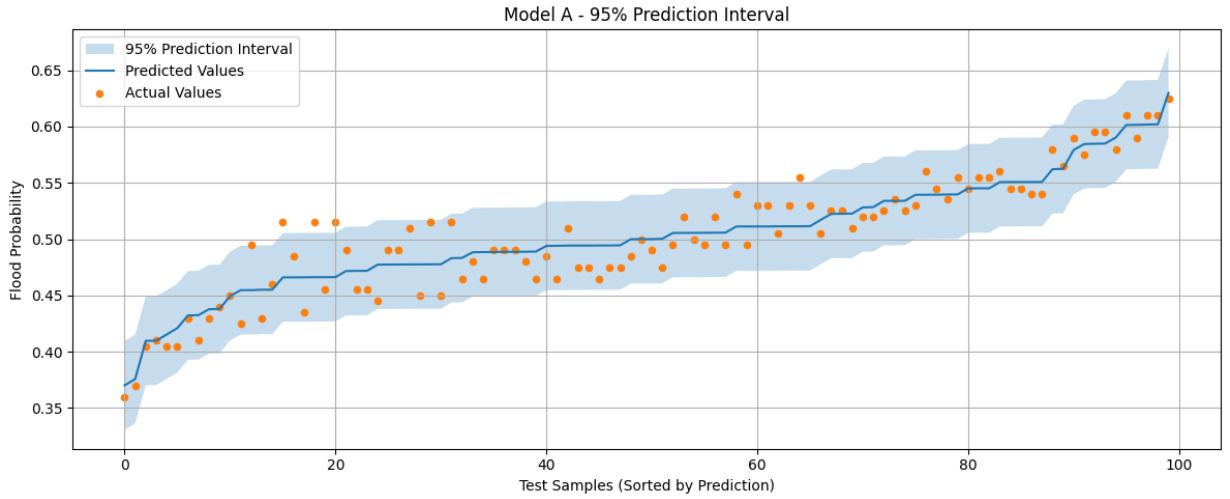


圖 3　模型 A 的 95% 預測區間，橘點為實際值，藍線為預測值，陰影為區間

實際抽樣涵蓋率：95.0%

測試集隨機抽取的 100 筆中，95 筆目標值位於計算的區間內。

本次涵蓋率只描述該 100 筆抽樣的結果，不代表未來每批資料都一定達到 95%。區間的統計意義依賴 OLS 模型假設，如模型形式、誤差分布與變異特性等。本研究尚未完整檢驗各項回歸假設，且線性回歸預測不會自動受限於 0～1。

5.4 模型選擇

綜合測試集的定量評估、散佈圖與簡易區間檢查，優先選擇 **模型 A（20 個特徵）** 作為此競賽資料研究的最終模型。後續若要部署到現實環境，仍須進行外部驗證、模型診斷與風險校準。

6. Deployment（模型應用示範）

6.1 新資料預測方式

利用訓練資料每個輸入特徵的中位數組合成一筆模擬輸入資料（本例各特徵中位數均為　5.0），分別由已訓練模型 A、B 進行預測。這是 Colab 中的推論示範，而非部署到網站或實際水文平台。

模型	輸入特徵	新資料預測值
模型 A	20 個	**0.5113**
模型 B	15 個	0.5095

兩組在這筆模擬資料上的預測只差 0.0018，但單一樣本預測接近不能證明兩模型整體表現相同。最終模型仍應由獨立測試集指標決定。

6.2 實務建議與未來研究

- 針對真實地理、水文與氣象資料重新蒐集、驗證與配適。
- 對線性關係、殘差、異質變異與共線性進行診斷。
- 實作 Ridge、Lasso 等正則化方法，使用交叉驗證調整參數。
- 如需將數值解釋為真實機率，應檢查校準結果並考慮更合適的建模方法。

> 結論：本研究的主要價值是建立完整 CRISP-DM 分析流程並以公平的測試集比較方法，而不是宣稱已完成可實際使用的洪水預報系統。

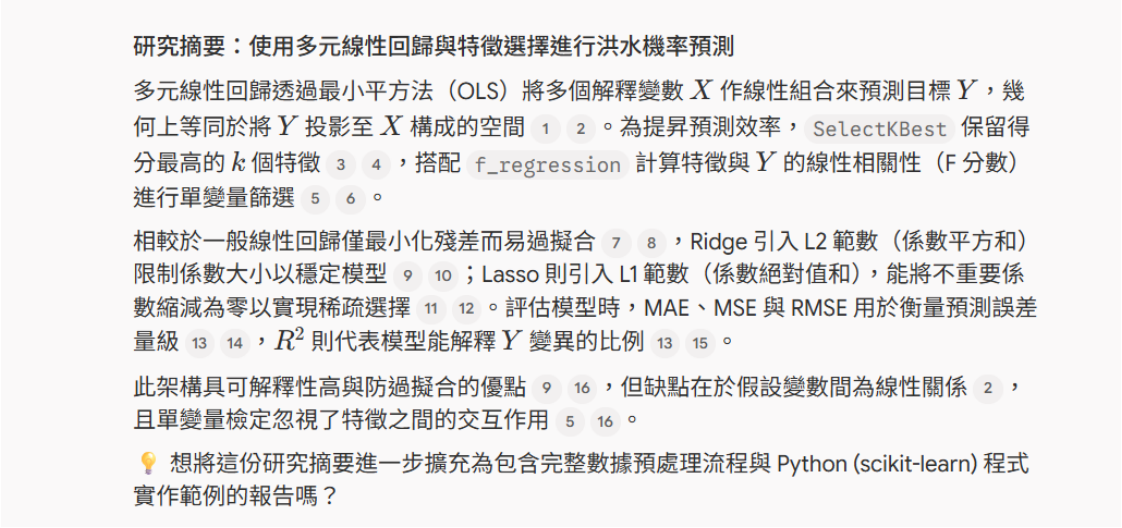
NotebookLM 研究摘要

來源：使用 NotebookLM 查詢與整合回歸、特徵選擇、模型評估等網路資料；以下文字依 2026/10/17 學生提供的 NotebookLM 研究摘要整理，保留其方法論重點。此段超過 100 個中文字。

> 多元線性回歸透過最小平方法（OLS），以多個解釋變數的線性組合預測目標值；幾何上可理解為將目標向量投影至輸入特徵張成的空間。特徵選擇方面，SelectKBest 可保留得分最高的 k 個特徵，搭配 f_regression 衡量單一特徵與目標之間的線性關聯，進行初步篩選。
>
> 相較於一般線性回歸只最小化殘差，Ridge 另外加入 L2 正則化項，使係數較小並改善部分共線性問題；Lasso 採用 L1 正則化，可把部分係數直接壓縮至零，形成較稀疏的模型。模型評估可以 MAE、MSE、RMSE 衡量預測誤差，並用 R^2 觀察模型對目標變異的解釋程度。這些方法具備可解釋性與降低過度擬合的優勢，但也可能受線性假設與單變量篩選限制，因此需要搭配實際測試集比較與必要的模型診斷。

NotebookLM 來源與研究方式

學生以 NotebookLM 匯入 Linear Regression、Ridge、Lasso、SelectKBest、f_regression、mean_squared_error、r2_score 等網頁研究來源，產出「洪水機率預測模型」摘要記事及「迴歸演算法比較分析」記事。研究比較的內容在下一頁整理為表格。



研究摘要：使用多元線性回歸與特徵選擇進行洪水機率預測

多元線性回歸透過最小平方法（OLS）將多個解釋變數 X 作線性組合來預測目標 Y，幾何上等同於將 Y 投影至 X 構成的空間 [1] [2]。為提昇預測效率，`SelectKBest` 保留得分最高的 k 個特徵 [3] [4]，搭配 `f_regression` 計算特徵與 Y 的線性相關性（F 分數）進行單變量篩選 [5] [6]。

相較於一般線性回歸僅最小化殘差而易過擬合 [7] [8]，Ridge 引入 L2 範數（係數平方和）限制係數大小以穩定模型 [9] [10]；Lasso 則引入 L1 範數（係數絕對值和），能將不重要係數縮減為零以實現稀疏選擇 [11] [12]。評估模型時，MAE、MSE 與 RMSE 用於衡量預測誤差量級 [13] [14]，R^2 則代表模型能解釋 Y 變異的比例 [13] [15]。

此架構具可解釋性高與防過擬合的優點 [9] [16]，但缺點在於假設變數間為線性關係 [2]，且單變量檢定忽視了特徵之間的交互作用 [5] [16]。

💡 想將這份研究摘要進一步擴充為包含完整數據預處理流程與 Python (scikit-learn) 程式實作範例的報告嗎？

圖 4　NotebookLM 生成之研究摘要截圖（學生提供）

主流回歸演算法比較

依 NotebookLM 匯入的教學與官方文件，整理三種可用於連續型目標預測的方法。以下屬**文獻比較**；本次 Notebook 實驗只訓練 LinearRegression，並未訓練 Ridge 或 Lasso。

方法	核心原理	優點	限制
Linear Regression 一般多元線性回歸	以 OLS 最小化殘差平方和，估計多個特徵的線性組合。	架構簡單、計算有效率、係數易解釋。	可能受多重共線性或過度擬合影響，無自動選特徵能力。
Ridge 嶺迴歸	在最小平方法目標加入 L2 係數平方和懲罰。	可穩定係數、在高度相關特徵下改善部分泛化表現。	通常無法直接將係數降至零，特徵仍保留。
Lasso 套索迴歸	在最小平方法目標加入 L1 係數絕對值和懲罰。	部分係數可變成零，有助於產生稀疏模型及特徵選擇。	高度相關特徵下選擇可能不穩定，需調整正則化強度。

應用於本研究的比較意義

本研究使用的 20 個數值特徵皆可直接投入一般線性回歸。從結果可知，單純使用 SelectKBest 減少 5 個特徵並未得到較高測試 R^2。因此，Ridge 與 Lasso 值得作為後續模型，但實際哪種較準仍需在相同 train/test 設定下訓練、調整超參數，再用相同指標比較，不能只依演算法特性推定。

網路上主流解法的參考

除一般線性回歸以外，常見的正則化解法包含 Ridge、Lasso；特徵選擇常見方法包括單變量統計篩選、遞迴特徵消除（RFE）與前向／後向順序選擇。考慮到本次作業已要求 SelectKBest，本研究將更複雜的特徵選擇與正則化建模列為進階方向，未將其列入已完成的實驗。

GPT 協助紀錄與研究反思

本作業使用 ChatGPT 作為學習與實作輔助。程式碼、數值、圖表皆以學生在 Google Colab 實際執行並儲存在 Notebook 中的結果為準；ChatGPT 的文字建議並不能取代程式執行及來源檢查。

輔助階段	GPT 提供的協助	學生確認方式
資料集選擇	解讀 10～20 特徵的要求、選用 Kaggle 洪水資料	下載 train.csv 並核對欄位數
資料理解／準備	說明 pandas 讀取、缺失值檢查、train_test_split	Colab 檢查資料大小與 80/20 筆數
特徵選擇／建模	提供 SelectKBest、LinearRegression 程式指引	實際輸出 15 個特徵與兩個模型指標
評估與繪圖	說明散佈圖、95% 預測區間與 R^2 的判讀	檢查 Notebook 產生的三張圖表
研究與報告	引導 NotebookLM 匯入資料與撰寫摘要，整理 CRISP-DM 文字	核對來源截圖及報告文字

> **繳交提醒：**本頁為「GPT 輔助內容摘要」，並非 ChatGPT 的完整逐字對話紀錄。依老師要求，需另外將本次完整 ChatGPT 對話透過瀏覽器列印或 pdfCrowd 等方式匯出為 PDF，與本報告一起放入 ZIP。

個人學習反思（依實作結果整理）

此次作業透過完整的 CRISP-DM 實作，練習了資料檢查、資料分割、特徵選擇、回歸建模與結果分析。最值得注意的是，雖然 SelectKBest 保留了 15 個與目標相關性較高的特徵，但其線性回歸模型表現明顯不如全部使用 20 個特徵。此結果提醒我們：特徵選擇不能只看分數排名，仍需要用未參與訓練的資料評估整體模型效果。

參考資料與繳交檢查

參考資料

[1] Kaggle. Regression with a Flood Prediction Dataset (Playground Series S4E5).
https://www.kaggle.com/competitions/playground-series-s4e5/data

[2] scikit-learn. LinearRegression.
https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

[3] scikit-learn. SelectKBest and f_regression.
https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.SelectKBest.html
https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.f_regression.html

[4] scikit-learn. Ridge and Lasso.
https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html
https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html

[5] NotebookLM（學生操作紀錄，2026/10/17）。「洪水機率預測模型」及「迴歸演算法比較分析」研究記事；本報告附學生提供之摘要截圖。

[6] 實驗程式與執行結果：7115056050_hw2.ipynb（Google Colab；2026/10/17）。

老師要求的繳交內容

檔案／內容	狀態
7115056050_hw2.ipynb（主程式）	已提供，可使用
7115056050_hw2_報告.pdf	本報告
NotebookLM 研究摘要、演算法比較	已在本報告整理，並有摘要截圖
ChatGPT 完整對話 PDF	須另行由使用者匯出
train.csv	請依老師要求確認是否一併附上；Notebook 本身不含 CSV
7115056050_hw2.zip	待完整收齊檔案後壓縮

報告寫作說明：所有數值與圖表來自使用者提交的 Notebook 儲存輸出；NotebookLM 研究摘要與演算法比較依使用者提供的 NotebookLM 截圖整理。未從外部重新訓練模型，也未假稱已實測 Ridge 或 Lasso。